DEPARTAMENTO DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico 2

Análisis y experimentación con modelos

1 de noviembre de 2026 — Laboratorio de Datos

Normalizados

Integrante	LU	Correo electrónico
Ayala Ignacio	196/25	ayalanacho11@gmail.com
Della Bonzana Lara	563/25	dellabonzanalara@gmail.com
Posse Lucila	618/25	lucila.posse@gmail.com
Ventroni Milena	647/25	milena.ventroni@gmail.com

Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires
Ciudad Universitaria - (Pabellón I/Planta Baja)
Intendente Güiraldes 2610 - C1428EGA
Ciudad Autónoma de Buenos Aires - Rep. Argentina
Tel/Fax: (++54 +11) 4576-3300
http://www.exactas.uba.ar

1. Introducción

El presente trabajo tiene como objetivo analizar y evaluar distintos modelos de clasificación supervisada a partir de un conjunto de imágenes pertenecientes al dataset Quick, Draw! de Google [1, 2]. Buscamos estudiar cómo la selección de atributos e hiperparámetros influye en el desempeño de los clasificadores y cómo estimar su capacidad para realizar predicciones sobre imágenes no utilizadas durante el entrenamiento. Cada imagen está representada por 784 atributos, correspondientes a los píxeles de una matriz de 28×28, y pertenece a una de diez clases posibles.

Para llevar a cabo el trabajo, realizamos inicialmente un análisis exploratorio de los datos, enfocado en estudiar la variabilidad de los atributos y las similitudes entre imágenes pertenecientes tanto a una misma clase como a clases diferentes.

A partir de este análisis, abordamos dos problemas de clasificación. En primer lugar, buscamos distinguir imágenes de cuadrados y casas mediante el algoritmo de los (k) vecinos más cercanos (KNN), evaluando cómo la selección de atributos y la cantidad de vecinos afectan el desempeño del modelo. Luego, trabajamos con las diez clases utilizando árboles de decisión. Para seleccionar sus hiperparámetros recurrimos a la validación cruzada y utilizamos un conjunto de control independiente para estimar su potencial generalización.

2. Análisis exploratorio de los datos

El conjunto de entrenamiento contiene 30.000 imágenes etiquetadas, mientras que el conjunto de evaluación cuenta con 6.030 imágenes sin etiquetar, identificadas mediante un código único. Comprobamos que los atributos son de tipo entero y que sus intensidades toman valores entre 0 y 255, de los cuales encontramos 143 valores distintos. No identificamos valores faltantes ni filas duplicadas en los conjuntos analizados.

Para determinar qué atributos podrían resultar útiles para distinguir las clases, analizamos la variabilidad de los píxeles mediante dos mapas de calor. El primero representa la varianza de las intensidades promedio de cada píxel entre las distintas clases, mientras que el segundo muestra el desvío estándar de cada píxel sobre el conjunto completo.

Como podemos observar en la Figura 1, la variabilidad no se distribuye uniformemente entre los atributos. Las mayores diferencias entre los promedios de clase se concentran principalmente cerca del borde superior y del lateral izquierdo de las imágenes, regiones donde también encontramos una elevada variabilidad total. En cambio, las esquinas presentan valores reducidos en ambos gráficos.

También comprobamos que ninguno de los 784 píxeles es estrictamente constante y que solamente ocho presentan un desvío estándar inferior a 10.

Estos resultados permiten identificar atributos potencialmente más relevantes para la clasificación. Sin embargo, consideramos que la variabilidad de un atributo no es suficiente para determinar su utilidad en la misma. Un píxel con poca variación podría aportar información para distinguir ciertas clases, mientras que uno con mayor variabilidad podría presentar diferencias importantes incluso entre imágenes de una misma categoría. Por lo tanto, aunque estos resultados nos permiten identificar atributos potencialmente relevantes, sería necesario evaluar el desempeño de los modelos con distintas selecciones de píxeles para determinar su utilidad.

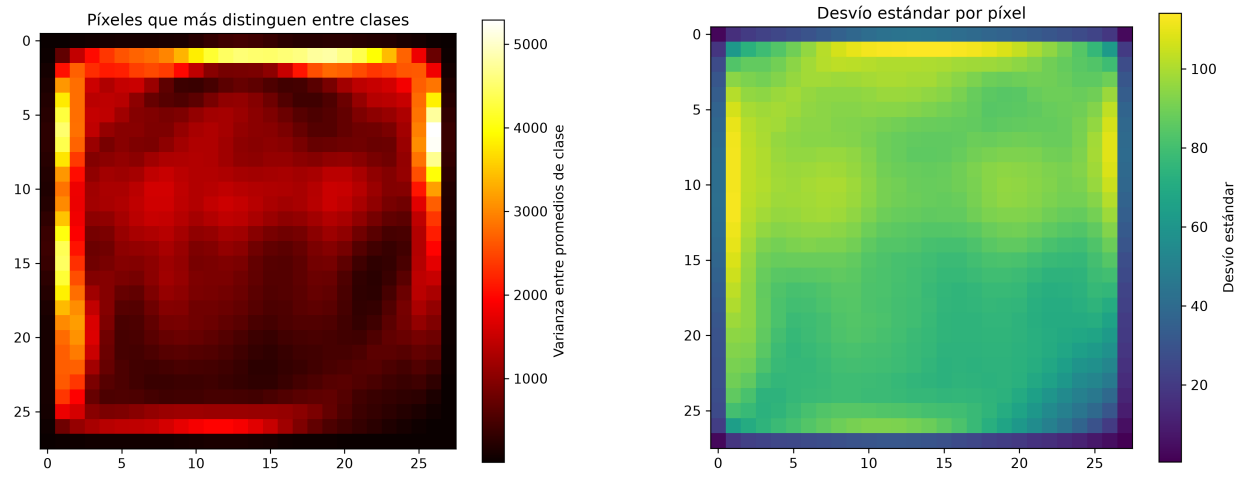


Figura 1: Variabilidad de los atributos. Izquierda: varianza de los promedios por clase. Derecha: desvío estándar de cada píxel sobre el conjunto completo.

Para complementar este análisis, comparamos las distribuciones de intensidad de dos atributos: `pixel194`, que presenta una de las mayores varianzas entre los promedios de clase, y `pixel0`, cuya variabilidad total es reducida.

Como podemos observar en la Figura 2, las intensidades del píxel 194 presentan diferencias importantes entre clases. Mientras que en algunas encontramos valores elevados y una amplia dispersión, en otras las intensidades se concentran principalmente en cero. Esto sugiere que el atributo podría aportar información relevante para distinguir determinadas categorías.

En cambio, el píxel 0 presenta intensidades prácticamente nulas en todas las clases, con algunos valores atípicos poco frecuentes. Por lo tanto, este atributo parece tener menor capacidad para diferenciar las clases por sí solo, aunque no podemos afirmar que sea completamente irrelevante al combinarlo con otros atributos.

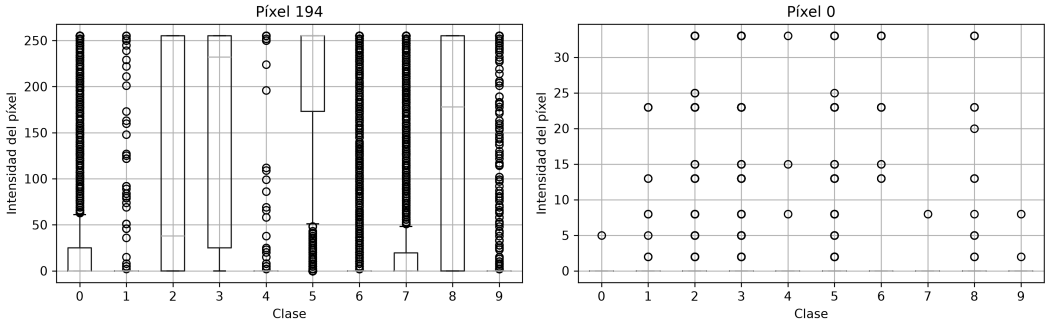


Figura 2: Distribución de las intensidades de los píxeles 194 y 0 según la clase de la imagen.

Luego, seleccionamos aleatoriamente ejemplos de las cuatro clases estudiadas en los siguientes apartados: cuadrados, casas, estrellas y peces.

Observar estos dibujos permite apreciar las diferentes formas en que puede representarse una misma categoría y contextualizar las medidas de variabilidad y distancia utilizadas posteriormente.

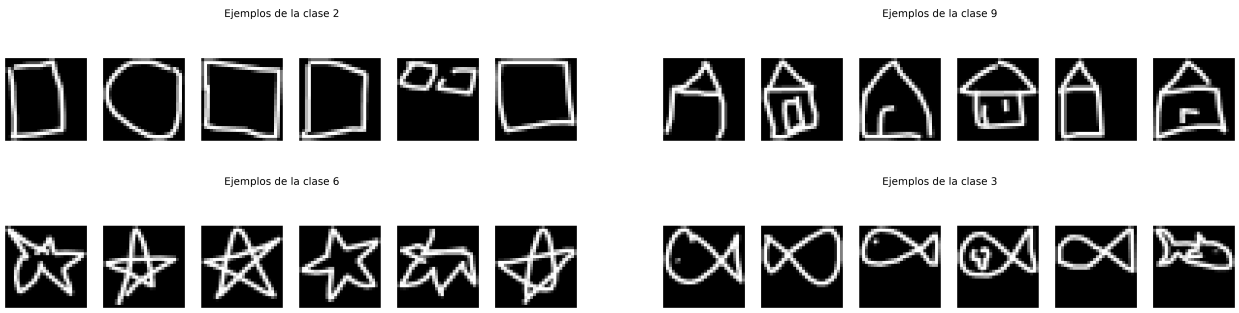


Figura 3: Ejemplos de imágenes seleccionadas aleatoriamente de cuatro clases del conjunto de datos. Arriba: cuadrados (2) y casas (9). Abajo: estrellas (6) y peces (3).

A continuación, analizamos las similitudes entre imágenes de cuadrados (clase 2), estrellas (clase 6) y casas (clase 9). Para ello, seleccionamos aleatoriamente 100 imágenes de cada categoría y calculamos las distancias euclídeas tanto entre imágenes de clases diferentes como entre imágenes de una misma clase.

A partir de la Figura 4, observamos que los cuadrados presentan las menores distancias internas, con una mediana de 2900,37, por lo que constituyen la clase más homogénea de las tres analizadas según esta medida. En cambio, las estrellas y las casas presentan medianas de 3240,39 y 3194,37, respectivamente, lo que refleja una mayor dispersión entre sus representaciones.

En cuanto a las distancias entre clases diferentes, encontramos que la mayor distancia media corresponde a cuadrados y estrellas (3502,25), seguidos de casas y estrellas (3369,07) y cuadrados y casas (3326,96).

Por lo tanto, los cuadrados y las estrellas presentan una mayor separación promedio que las demás clases. Esto sugiere que podrían resultar más fáciles de diferenciar mediante un clasificador basado en distancias.

Sin embargo, observamos un solapamiento considerable entre la distribución de distancias internas y entre clases. Por lo tanto, no podemos asegurar que esta mayor separación se traduzca necesariamente en un mejor desempeño predictivo.

Además, debemos considerar que la distancia euclídea compara las intensidades de los píxeles en posiciones correspondientes. En consecuencia, dibujos visualmente similares pueden presentar distancias elevadas si difieren en su ubicación, tamaño u orientación.

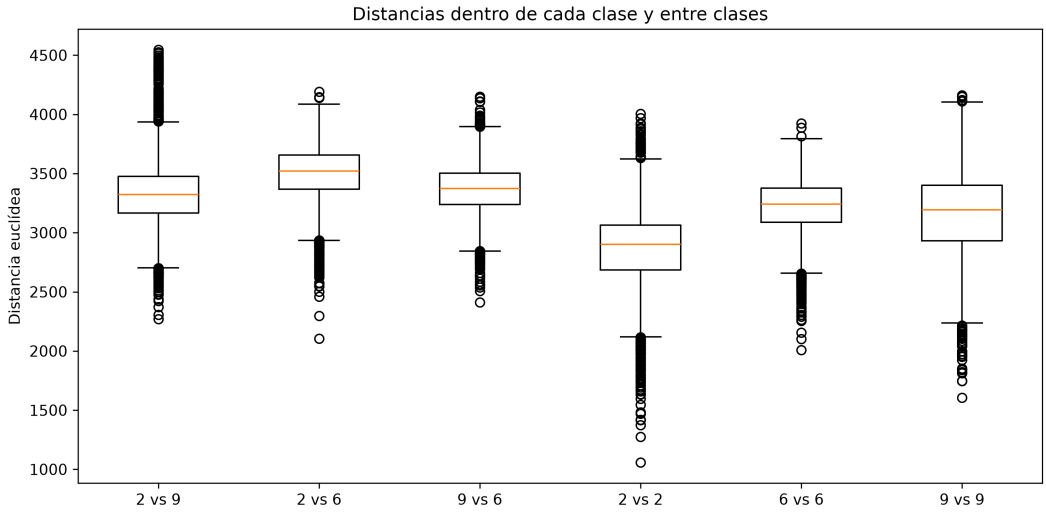


Figura 4: Distribución de las distancias euclídeas entre imágenes de una misma clase y de clases diferentes.

Por último, estudiamos la similitud entre las imágenes de la clase 3 (peces). Para ello, construi-

mos una imagen promedio a partir de las intensidades medias de sus píxeles y un mapa de desvío estándar que nos permitió visualizar la variabilidad interna de la categoría.

Como se observa en la Figura 5, la imagen promedio presenta una forma difusa, lo que sugiere diferencias entre las representaciones de los peces. Por otra parte, notamos que la mayor variabilidad se concentra en la región superior y los laterales de las imágenes, mientras que la región inferior presenta valores considerablemente menores.

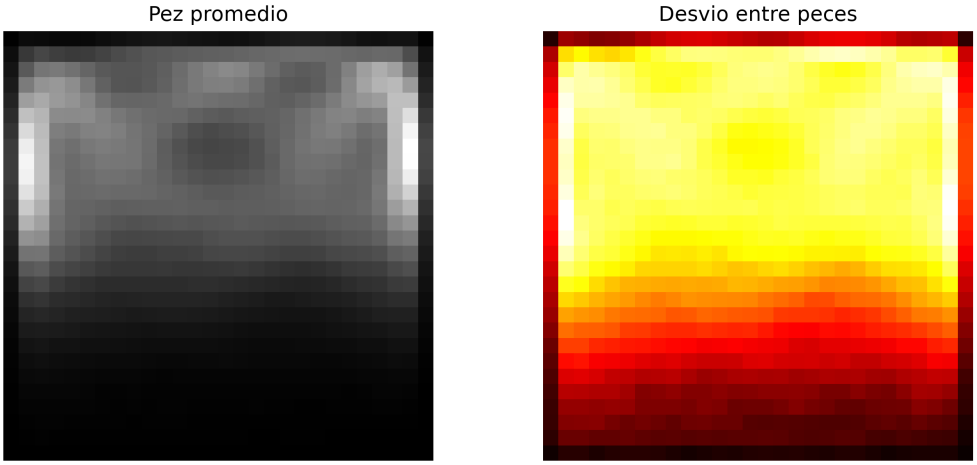


Figura 5: Imagen promedio y desvío estándar por píxel de la clase 3 (peces).

Para complementar estas observaciones, comparamos las distancias euclídeas entre pares de peces, entre peces y cuadrados y entre pares de cuadrados.

En la Figura 6 observamos que las distancias internas entre peces presentan una mediana cercana a 2900, ligeramente inferior a la distancia mediana entre peces y cuadrados, próxima a 3120. Sin embargo, las distribuciones se solapan considerablemente y las distancias internas de peces y cuadrados son similares.

Por lo tanto, encontramos variaciones apreciables entre las representaciones de peces, aunque su dispersión interna no resulta particularmente elevada en comparación con la de los cuadrados, según la distancia empleada. Estas observaciones no permiten determinar por sí solas qué tan fácilmente pueden clasificarse las imágenes de esta categoría.

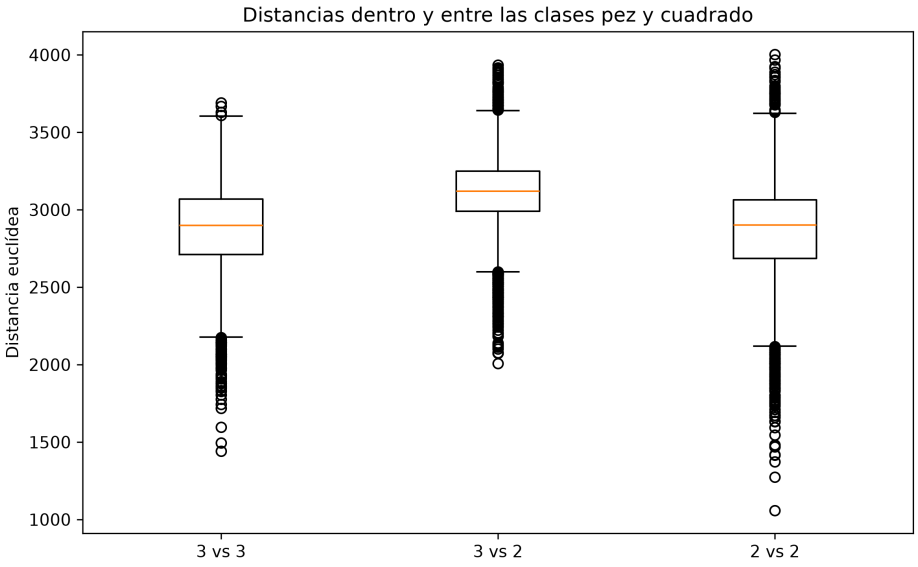


Figura 6: Distribución de las distancias euclídeas dentro de las clases 3 y 2, y entre ambas clases.

El análisis exploratorio de imágenes presenta dificultades asociadas a su alta dimensionalidad y a la importancia de la disposición espacial de los píxeles. El estudio individual de las intensidades no permite recuperar completamente las formas de los dibujos, mientras que diferencias en la posición, el tamaño o la orientación pueden generar variaciones importantes dentro de una misma clase.

Para abordar estas dificultades, combinamos herramientas estadísticas y visuales que nos permitieron identificar patrones de variabilidad y similitud. Sin embargo, estos resultados no permiten determinar por sí solos la capacidad predictiva de los atributos ni la separabilidad de las clases. Por ello, en los siguientes ejercicios evaluamos empíricamente el desempeño de distintos clasificadores y cómo este cambia según los atributos e hiperparámetros seleccionados.

3. Clasificación binaria mediante KNN

3.1. Preparación de los datos y métricas de evaluación

Para el primer problema de clasificación, trabajamos únicamente con las imágenes correspondientes a cuadrados (clase 2) y casas (clase 9), utilizando el algoritmo de los k vecinos más cercanos (KNN).

El subconjunto resultante contiene 6.030 imágenes: 3.085 cuadrados (51,16 %) y 2.945 casas (48,84 %). Dado que ambas categorías presentan proporciones similares, consideramos que el conjunto se encuentra balanceado.

Para evaluar los modelos, utilizamos accuracy, precision, recall y F1-score. Dado que el conjunto se encuentra balanceado, consideramos que la accuracy constituye una medida adecuada del desempeño general, ya que permite calcular la proporción total de predicciones correctas.

Complementamos esta medida con precision y recall, considerando a las casas como clase positiva. La primera indica qué proporción de las imágenes clasificadas como casas realmente corresponde a esa categoría, mientras que la segunda representa qué proporción de las casas fue identificada correctamente.

Por último, utilizamos el F1-score para comparar las distintas configuraciones de KNN, ya que combina precision y recall en una única medida. Esto nos permite considerar conjuntamente ambos tipos de errores: clasificar cuadrados como casas y clasificar casas como cuadrados.

Posteriormente, dividimos los datos aleatoriamente en un conjunto de entrenamiento (70 %) y uno de prueba (30 %). Utilizamos una partición estratificada para conservar aproximadamente las proporciones originales de ambas clases en los dos conjuntos.

3.2. Selección de atributos

Para estudiar cómo influye la selección de atributos en el desempeño de KNN, realizamos distintos experimentos manteniendo fija la cantidad de vecinos en $k = 5$.

En primer lugar, calculamos para cada píxel la diferencia absoluta entre su intensidad promedio en las imágenes de cuadrados y casas. Utilizamos exclusivamente el conjunto de entrenamiento para realizar estos cálculos, evitando incorporar información del conjunto de prueba en la selección de atributos.

A partir de estas diferencias, ordenamos los píxeles de mayor a menor y construimos cinco conjuntos distintos de tres atributos, seleccionados entre los ocho mejor posicionados. Para comparar este criterio con una selección aleatoria, también evaluamos cinco conjuntos de tres píxeles elegidos al azar.

Los conjuntos seleccionados mediante el ranking obtuvieron valores de F1-score entre 0,845 y 0,856, presentando resultados relativamente similares. En cambio, las selecciones aleatorias mostraron una mayor variabilidad, con valores entre 0,478 y 0,900. Incluso, una de las combinaciones aleatorias obtuvo el mejor desempeño entre los conjuntos de tres atributos evaluados.

Estos resultados sugieren que seleccionar los píxeles con mayores diferencias entre los promedios de clase no garantiza obtener la combinación más adecuada para KNN. Asimismo, observamos que

el desempeño puede variar considerablemente según los atributos seleccionados, incluso cuando se mantiene fija su cantidad.

Posteriormente, analizamos cómo cambia el desempeño al aumentar la cantidad de atributos. Para ello, entrenamos modelos utilizando los primeros 1, 2, 3, 5, 10, 50 y 100 píxeles del ranking.

Encontramos una mejora importante a medida que incorporamos más atributos. Con tres píxeles, obtuvimos un F1-score de 0,845, mientras que con diez aumentó a 0,915 y con cien alcanzó 0,968. Este último modelo también obtuvo una accuracy de 0,968.

Las matrices de confusión permiten observar esta mejora con mayor detalle. Mientras que el modelo con tres píxeles clasificó incorrectamente 222 cuadrados y 75 casas, el modelo con cien píxeles redujo estos errores a 28 y 29, respectivamente.

Por lo tanto, los resultados indican que incorporar una mayor cantidad de atributos mejoró el desempeño de KNN en los experimentos realizados. Sin embargo, todavía resta analizar cómo se comporta el modelo con otras cantidades de vecinos y con el conjunto completo de atributos.

Todas las pruebas se realizaron utilizando la misma partición, con el objetivo de comparar las distintas configuraciones de KNN bajo las mismas condiciones.

3.3. Comparación de hiperparámetros y resultados

Para profundizar el análisis anterior, evaluamos cómo influyen conjuntamente la cantidad de atributos y el número de vecinos en el desempeño de KNN.

Consideramos ocho valores de k (1, 3, 5, 7, 11, 15, 25 y 30) y diez cantidades de atributos (1, 2, 3, 5, 10, 20, 50, 100, 200 y 784), obteniendo un total de 80 configuraciones. En todos los casos, utilizamos los primeros píxeles del ordenamiento construido anteriormente y mantuvimos los mismos conjuntos de entrenamiento y prueba.

Como podemos observar en la Figura 7, la cantidad de atributos tiene una influencia considerable sobre el desempeño. Con menos de diez píxeles, los valores de F1-score se mantienen aproximadamente entre 0,83 y 0,86. Al incorporar más atributos, encontramos una mejora importante, alcanzando valores superiores a 0,95 con 50 a 200 píxeles.

Sin embargo, esta mejora no continúa al utilizar los 784 atributos disponibles. Para todos los valores de k evaluados, los modelos con 200 píxeles obtuvieron un F1-score superior al de aquellos que utilizaron el conjunto completo. Esto sugiere que incorporar atributos adicionales no siempre resulta beneficioso para KNN, posiblemente porque algunos aportan información poco relevante y afectan las distancias entre las imágenes.

Por otra parte, observamos que el efecto de modificar k depende de la cantidad de atributos utilizados. Con pocos píxeles, aumentar el número de vecinos produjo pequeñas mejoras en algunos casos, mientras que con cantidades mayores las diferencias fueron reducidas y no siguieron una tendencia uniforme.

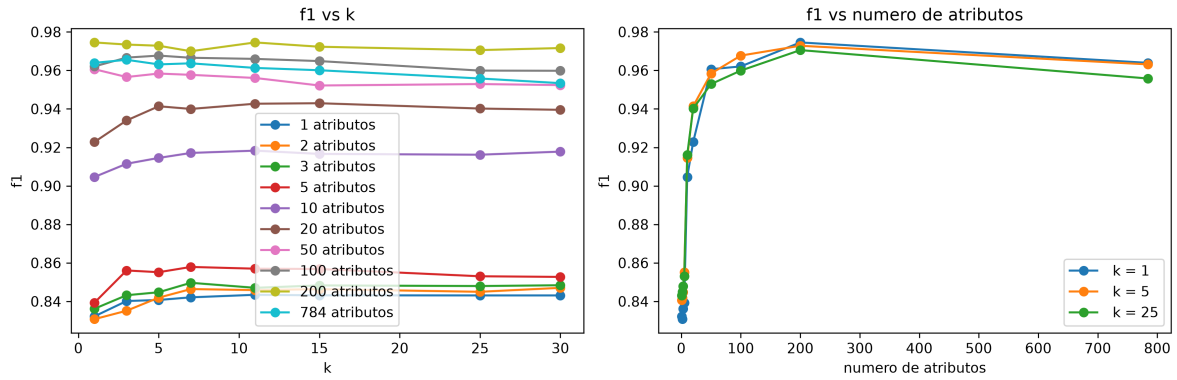


Figura 7: Desempeño de KNN según la cantidad de vecinos y de atributos utilizados. Izquierda: F1-score en función de k. Derecha: F1-score según la cantidad de atributos para distintos valores de k.

Entre las 80 configuraciones evaluadas, el mayor F1-score fue de 0,975, obtenido con $k = 1$ y los 200 primeros atributos del ordenamiento.

En conjunto, los resultados muestran que la selección y la cantidad de atributos tuvieron una influencia importante sobre el desempeño de KNN. Si bien la cantidad de vecinos también produjo diferencias, estas fueron generalmente menores que las observadas al modificar los atributos.

Cabe señalar que todas las configuraciones fueron comparadas utilizando el mismo conjunto de prueba. Por lo tanto, el mejor resultado observado no constituye por sí solo una estimación independiente del desempeño que tendría esa configuración sobre nuevas imágenes.

4. Clasificación multiclase mediante árboles de decisión

4.1. Preparación de los datos y métricas de evaluación

Para el segundo problema de clasificación, buscamos predecir a cuál de las diez clases pertenece cada imagen mediante árboles de decisión.

En primer lugar, dividimos el conjunto de 30.000 imágenes etiquetadas en dos subconjuntos: desarrollo (80 %) y control o held-out (20 %). Realizamos una partición aleatoria estratificada para conservar aproximadamente las proporciones originales de las clases.

Utilizamos el conjunto de desarrollo para entrenar y comparar distintas configuraciones del modelo, mientras que reservamos el conjunto de control para evaluar su desempeño una vez seleccionados los hiperparámetros.

Como métrica principal elegimos F1 macro, que calcula el F1-score de cada clase y luego promedia los resultados, otorgando la misma importancia a todas las categorías, independientemente de su cantidad de observaciones.

Preferimos esta medida frente al F1 ponderado, ya que nos interesa evaluar el desempeño en todas las clases por igual, sin otorgar mayor peso a aquellas con más imágenes. Además, consideramos que utilizar únicamente accuracy podría ocultar diferencias importantes en la capacidad del modelo para reconocer determinadas categorías.

Complementamos el F1 macro con accuracy, precision macro y recall macro. De esta manera, buscamos evaluar tanto la proporción general de predicciones correctas como las diferencias en el desempeño del clasificador entre clases.

4.2. Selección de hiperparámetros mediante validación cruzada

Para seleccionar el árbol de decisión, comparamos distintas configuraciones de hiperparámetros. Consideramos dos criterios de división (`gini` y `entropy`), profundidades máximas entre 1 y 10 y dos valores para la cantidad mínima de muestras por hoja (1 y 5).

Evaluamos las 40 combinaciones resultantes mediante validación cruzada estratificada de cinco particiones sobre el conjunto de desarrollo.

En cada iteración, entrenamos el modelo utilizando cuatro particiones y evaluamos su desempeño sobre la restante. Repetimos el procedimiento hasta utilizar cada partición como conjunto de validación.

Para comparar las configuraciones, calculamos el F1 macro promedio de las cinco evaluaciones y registramos también su desvío estándar.

Finalmente, seleccionamos la configuración que obtuvo el mayor F1 macro promedio. Durante todo este procedimiento mantuvimos apartado el conjunto held-out, evitando utilizar sus observaciones para elegir los hiperparámetros.

A partir de los resultados obtenidos, seleccionamos el árbol con criterio de división `entropy`, profundidad máxima de 10 y un mínimo de cinco muestras por hoja. Esta configuración alcanzó un F1 macro promedio de 0,7816, con un desvío estándar de 0,0048 entre las cinco particiones.

Además del F1 macro utilizado para seleccionar el modelo, calculamos las restantes métricas sobre las cinco particiones de validación cruzada. Obtuvimos una accuracy promedio de 0,7820, una

precision macro de 0,7824 y un recall macro de 0,7821. Estos resultados muestran un desempeño similar entre las distintas métricas consideradas.

Observamos que las configuraciones con mayor desempeño utilizaron una profundidad máxima de 10, el valor más alto considerado en el experimento. Esto sugiere que permitir una mayor profundidad resultó beneficioso dentro del rango evaluado, aunque no podemos determinar cómo se comportaría el modelo con profundidades superiores.

Por otra parte, las diferencias entre las mejores configuraciones fueron reducidas. En particular, el segundo modelo, también con criterio `entropy` y profundidad 10, pero con una muestra mínima por hoja, obtuvo un F1 macro promedio de 0,7810.

Si bien seleccionamos la configuración con mayor F1 macro promedio, estos resultados no permiten afirmar que su desempeño sea considerablemente superior al de otras configuraciones cercanas.

Cuadro 1: Mejores configuraciones de árboles de decisión según validación cruzada.

Criterio	Profundidad	Mín. hoja	F1 macro
Entropy	10	5	0,7816
Entropy	10	1	0,7810
Gini	10	5	0,7797

4.3. Evaluación sobre el conjunto de control

Una vez seleccionada la mejor configuración mediante validación cruzada, entrenamos el árbol de decisión utilizando las 24.000 imágenes del conjunto de desarrollo. Posteriormente, evaluamos su desempeño sobre las 6.000 imágenes del conjunto held-out, que hasta este momento no habían sido utilizadas para entrenar ni seleccionar el modelo.

Obtuvimos una accuracy de 0,8003, una precision macro de 0,8013, un recall macro de 0,8005 y un F1 macro de 0,7998. Por lo tanto, el modelo logró clasificar correctamente aproximadamente el 80 % de las imágenes del conjunto de control.

Al comparar estos resultados con los obtenidos durante la validación cruzada, observamos que el F1 macro fue ligeramente superior en held-out (0,7998 frente a 0,7816). Esta diferencia puede estar relacionada con las particularidades de las particiones utilizadas y con el entrenamiento del modelo final sobre todo el conjunto de desarrollo.

Como podemos observar en la Figura 8, la matriz de confusión presenta una diagonal principal predominante, lo que indica que la mayoría de las imágenes fueron clasificadas correctamente. Sin embargo, el desempeño no fue uniforme entre las diez categorías.

En particular, las estrellas (clase 6) presentaron el menor F1-score (0,74), mientras que las casas (clase 9) obtuvieron el menor recall (0,71), lo que indica que una proporción importante de estas imágenes fue clasificada incorrectamente.

Por otra parte, los triángulos (clase 4) alcanzaron el mayor recall (0,92), pero presentaron una precision de 0,76. Esto indica que el modelo logró identificar la mayoría de las imágenes de esta categoría, aunque también clasificó incorrectamente como triángulos dibujos de otras clases.

Estas diferencias muestran que, aunque el desempeño general del modelo fue cercano al 80 %, existen variaciones importantes en su capacidad para reconocer las distintas categorías.

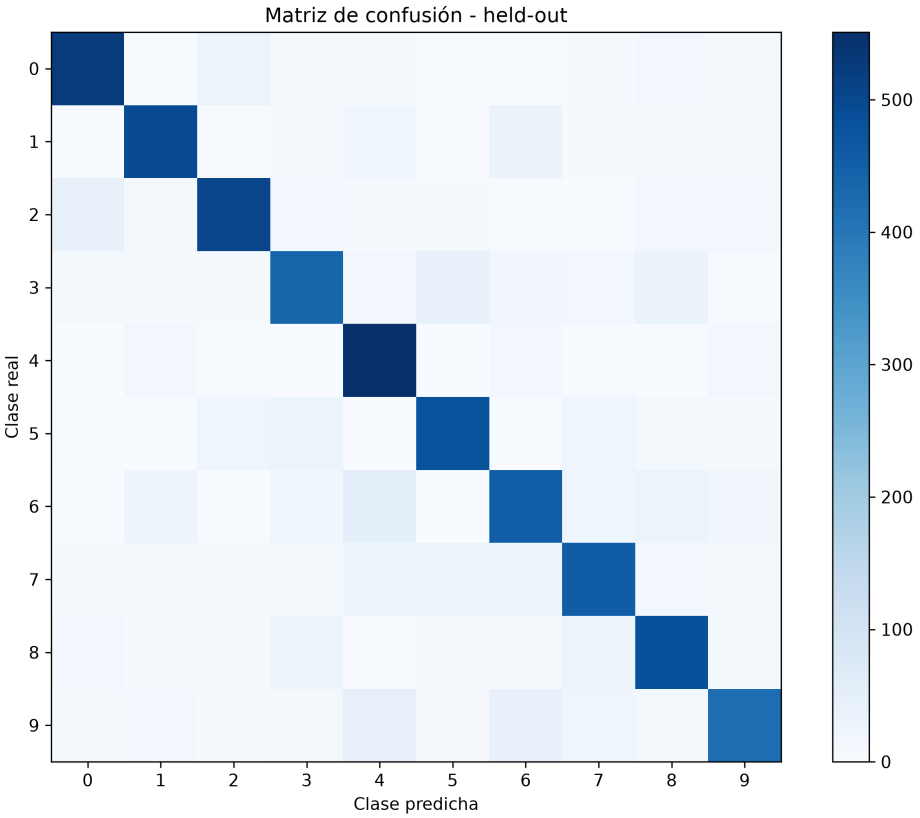


Figura 8: Matriz de confusión del árbol de decisión seleccionado, evaluado sobre el conjunto held-out. Las filas representan las clases reales y las columnas las clases predichas.

4.4. Predicciones y estimación del desempeño

Finalmente, utilizamos el árbol de decisión seleccionado para predecir las clases de las 6.030 imágenes del conjunto de evaluación proporcionado por la cátedra. Generamos un archivo CSV que contiene los identificadores originales de cada imagen y sus respectivas clases predichas.

Como estimación del desempeño sobre este conjunto, utilizamos la accuracy obtenida sobre held-out, cuyo valor fue de 0,8003. Elegimos esta medida porque el conjunto de control se mantuvo apartado durante el entrenamiento y la selección de hiperparámetros, por lo que permite evaluar el modelo sobre imágenes que no habían sido utilizadas previamente.

Consideramos que esta estimación resulta razonable porque ambos conjuntos provienen del mismo problema de clasificación y presentan las mismas características en cuanto a la representación de las imágenes. Sin embargo, el desempeño real podría presentar pequeñas diferencias debido a las particularidades de las imágenes incluidas en el conjunto de evaluación.

Para comparar nuestra estimación con los resultados obtenidos durante la selección del modelo, calculamos también la accuracy promedio de las cinco particiones de validación cruzada, que fue de 0,7820. Este valor resultó ligeramente inferior al obtenido sobre held-out (0,8003).

Consideramos que esta diferencia podría estar relacionada con que, durante la validación cruzada, los modelos se entrenaron utilizando una menor cantidad de imágenes que el árbol definitivo, aunque también pueden influir las particularidades de las distintas particiones.

Por lo tanto, esperamos que la accuracy real sobre el conjunto de evaluación de la cátedra sea cercana a 0,8003 y, en consecuencia, ligeramente superior a la obtenida durante la validación cruzada. Sin embargo, reconocemos que se trata de una estimación y que el desempeño final puede variar según las características de las imágenes evaluadas.

5. Conclusiones

A lo largo del trabajo, analizamos distintas características del conjunto de imágenes y evaluamos cómo la selección de atributos y de hiperparámetros influye en el desempeño de los modelos de clasificación.

El análisis exploratorio nos permitió identificar diferencias en la variabilidad de los píxeles y en las representaciones de las distintas categorías. Sin embargo, también observamos que estas medidas no resultan suficientes para determinar por sí solas la utilidad de un atributo o la facilidad con la que pueden distinguirse dos clases.

En los experimentos de clasificación binaria mediante KNN, encontramos que la selección y la cantidad de atributos tuvieron una influencia importante sobre los resultados. Aunque algunos conjuntos de tres píxeles permitieron distinguir cuadrados de casas con un desempeño razonable, incorporar más atributos produjo mejoras considerables. No obstante, utilizar los 784 píxeles disponibles resultó menos efectivo que emplear una selección de 200 atributos. La mejor configuración evaluada alcanzó un F1-score de 0,975, utilizando 200 píxeles y un único vecino.

Por otra parte, en la clasificación multiclase mediante árboles de decisión, seleccionamos los hiperparámetros utilizando validación cruzada sobre el conjunto de desarrollo. El modelo elegido obtuvo una accuracy de 0,8003 sobre el conjunto de control, que se había mantenido apartado durante el entrenamiento y la selección.

Este resultado nos permitió estimar el desempeño esperado sobre las imágenes de evaluación de la cátedra sin utilizar información de sus etiquetas. Consideramos que la separación entre desarrollo y control fue fundamental para obtener una estimación más independiente de la capacidad de generalización del modelo, aunque reconocemos que el desempeño real puede presentar diferencias.

En conjunto, los experimentos muestran la importancia de evaluar empíricamente las decisiones tomadas durante la construcción de un clasificador. Los resultados también destacan la necesidad de distinguir entre el desempeño observado al comparar configuraciones y aquel obtenido sobre datos que no participaron de su selección.

6. Bibliografía

Referencias

[1] Ha, D. y Eck, D. (2017). *A Neural Representation of Sketch Drawings.* arXiv preprint arXiv:1704.03477. `https://arxiv.org/abs/1704.03477`

[2] Google Creative Lab (2017). *The Quick, Draw! Dataset.* GitHub. `https://github.com/googlecreativelab/quickdraw-dataset`