DEPARTAMENTO DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico 2

Análisis y experimentación con modelos

1 de noviembre de 2026 — Laboratorio de Datos

Normalizados

Integrante	LU	Correo electrónico
Ayala Ignacio	196/25	ayalanacho11@gmail.com
Della Bonzana Lara	563/25	dellabonzanalara@gmail.com
Posse Lucila	618/25	lucila.posse@gmail.com
Ventroni Milena	647/25	milena.ventroni@gmail.com

Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires
Ciudad Universitaria - (Pabellón I/Planta Baja)
Intendente Güiraldes 2610 - C1428EGA
Ciudad Autónoma de Buenos Aires - Rep. Argentina
Tel/Fax: (++54 +11) 4576-3300
http://www.exactas.uba.ar

1. Introducción y análisis exploratorio

El presente trabajo tiene como objetivo analizar y evaluar distintos modelos de clasificación supervisada a partir de un conjunto de imágenes pertenecientes al dataset Quick, Draw! de Google. Buscamos estudiar cómo la selección de atributos y de hiperparámetros influye en el desempeño de los clasificadores y, particularmente, cómo estimar su capacidad para realizar predicciones sobre imágenes no utilizadas durante el entrenamiento. Cada imagen está representada por 784 atributos, correspondientes a los píxeles de una matriz de 28×28, y pertenece a una de diez clases posibles.

Para llevar a cabo el trabajo, realizamos inicialmente un análisis exploratorio de los datos, enfocado en estudiar la variabilidad de los atributos y las similitudes entre imágenes de una misma clase y de clases diferentes.

A partir de este análisis, abordamos dos problemas de clasificación. En primer lugar, buscamos distinguir imágenes de cuadrados y casas mediante el algoritmo de los (k) vecinos más cercanos (KNN), evaluando cómo la selección de atributos y la cantidad de vecinos afectan el desempeño del modelo. Luego, trabajamos con las diez clases utilizando árboles de decisión. Para seleccionar sus hiperparámetros recurrimos a la validación cruzada y utilizamos un conjunto de control independiente para estimar su capacidad de generalización.

1.1. Análisis exploratorio

El conjunto de entrenamiento contiene 30.000 imágenes etiquetadas, mientras que el conjunto de evaluación cuenta con 6.030 imágenes sin etiquetar, identificadas mediante un código único. Comprobamos que los atributos son de tipo entero y que sus intensidades toman valores entre 0 y 255, de los cuales encontramos 143 valores distintos. Tampoco identificamos valores faltantes ni filas duplicadas en los conjuntos analizados.

Para determinar qué atributos podrían resultar útiles para distinguir las clases, analizamos la variabilidad de los píxeles mediante dos mapas de calor. El primero representa la varianza de las intensidades promedio de cada píxel entre las distintas clases, mientras que el segundo muestra el desvío estándar de cada píxel sobre el conjunto completo.

Como podemos observar en la Figura 1, la variabilidad no se distribuye uniformemente entre los atributos. Las mayores diferencias entre los promedios de clase se concentran principalmente cerca del borde superior y del lateral izquierdo de las imágenes, regiones donde también encontramos una elevada variabilidad total. En cambio, las esquinas presentan valores reducidos en ambos gráficos.

También comprobamos que ninguno de los 784 píxeles es estrictamente constante y que solamente ocho presentan un desvío estándar inferior a 10.

Estos resultados permiten identificar atributos potencialmente más relevantes para la clasificación. Sin embargo, una baja variabilidad total no implica necesariamente una baja capacidad discriminativa. Del mismo modo, una variabilidad elevada puede deberse a diferencias entre dibujos de una misma clase. Por lo tanto, estos gráficos permiten formular hipótesis sobre la relevancia de los atributos, pero no garantizan que eliminar determinados píxeles mejore o preserve el desempeño de un clasificador.

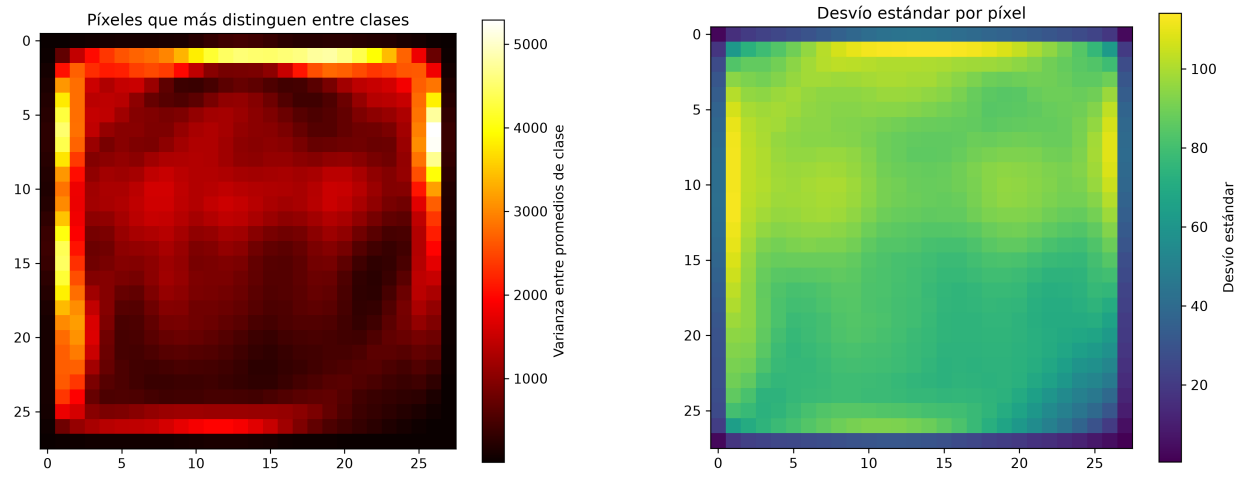


Figura 1: Variabilidad de los atributos. Izquierda: varianza de los promedios por clase. Derecha: desvío estándar de cada píxel sobre el conjunto completo.

Para complementar este análisis, comparamos las distribuciones de intensidad de dos atributos: `pixel194`, que presenta una de las mayores varianzas entre los promedios de clase, y `pixel0`, cuya variabilidad total es reducida.

Como podemos observar en la Figura 2, las intensidades del píxel 194 presentan diferencias importantes entre clases. Mientras que en algunas encontramos valores elevados y una amplia dispersión, en otras las intensidades se concentran principalmente en cero. Esto sugiere que el atributo podría aportar información relevante para distinguir determinadas categorías.

En cambio, el píxel 0 presenta intensidades prácticamente nulas en todas las clases, con algunos valores atípicos poco frecuentes. Por lo tanto, este atributo parece tener menor capacidad para diferenciar las clases por sí solo, aunque no podemos afirmar que sea completamente irrelevante al combinarlo con otros atributos.

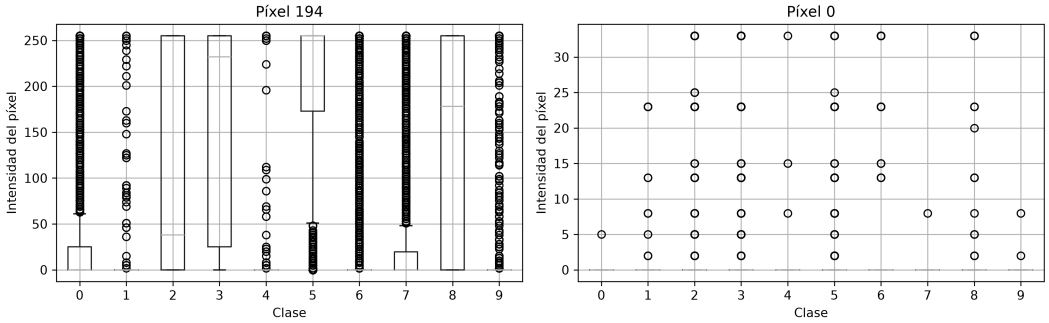


Figura 2: Distribución de las intensidades de los píxeles 194 y 0 según la clase de la imagen.

Para complementar el análisis estadístico, seleccionamos aleatoriamente ejemplos de las cuatro clases estudiadas en los siguientes apartados: cuadrados, casas, estrellas y peces.

La inspección visual de estos dibujos permite apreciar las diferentes formas en que puede representarse una misma categoría y contextualizar las medidas de variabilidad y distancia utilizadas posteriormente.

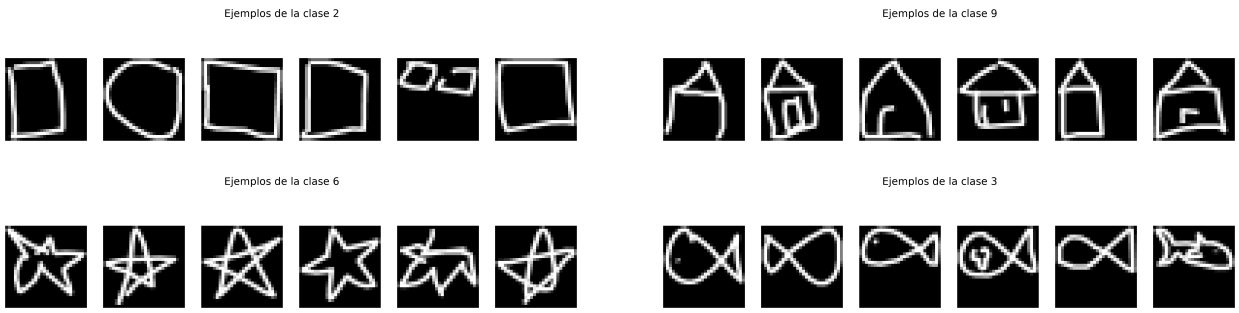


Figura 3: Ejemplos de imágenes seleccionadas aleatoriamente de cuatro clases del conjunto de datos. Arriba: cuadrados (2) y casas (9). Abajo: estrellas (6) y peces (3).

A continuación, analizamos las similitudes entre imágenes de cuadrados (clase 2), estrellas (clase 6) y casas (clase 9). Para ello, seleccionamos aleatoriamente 100 imágenes de cada categoría y calculamos las distancias euclídeas tanto entre imágenes de clases diferentes como entre imágenes de una misma clase.

A partir de la Figura 4, observamos que los cuadrados presentan las menores distancias internas, con una mediana de 2900,37, por lo que constituyen la clase más homogénea de las tres analizadas según esta medida. En cambio, las estrellas y las casas presentan medianas de 3240,39 y 3194,37, respectivamente, lo que refleja una mayor dispersión entre sus representaciones.

En cuanto a las distancias entre clases diferentes, encontramos que la mayor distancia media corresponde a cuadrados y estrellas (3502,25), seguidos de casas y estrellas (3369,07) y cuadrados y casas (3326,96). Por lo tanto, los cuadrados y las estrellas presentan las mayores diferencias promedio según la distancia euclídea utilizada.

No obstante, observamos un solapamiento considerable entre las distribuciones de distancias internas y entre clases. Esto nos permite reconocer diferencias en la homogeneidad y separación de las categorías, pero no determinar por sí solo cuáles resultarán más fáciles de distinguir mediante un clasificador.

Además, debemos considerar que la distancia euclídea compara las intensidades de los píxeles en posiciones correspondientes. En consecuencia, dibujos visualmente similares pueden presentar distancias elevadas si difieren en su ubicación, tamaño u orientación.

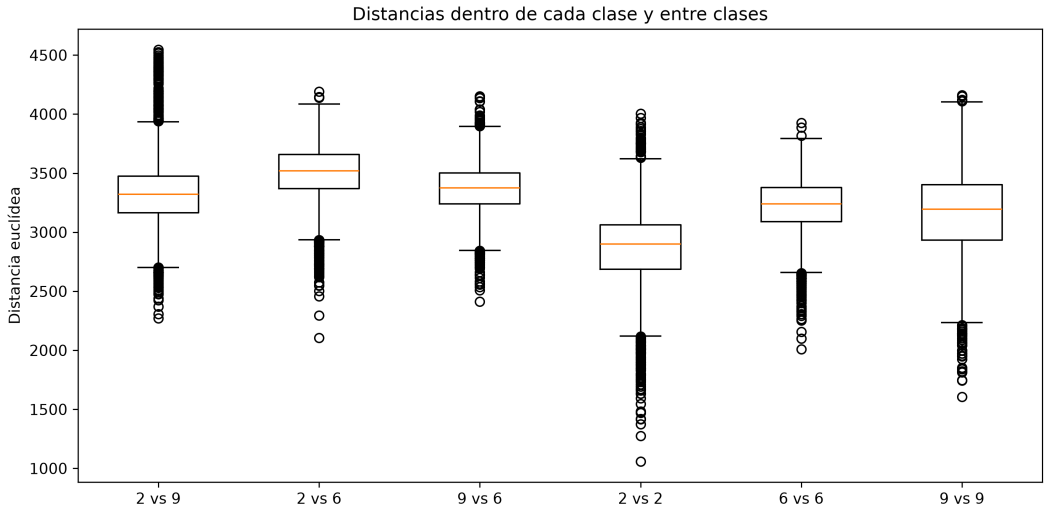


Figura 4: Distribución de las distancias euclídeas entre imágenes de una misma clase y de clases diferentes.

Por último, estudiamos la similitud entre las imágenes de la clase 3 (peces). Para ello, construimos una imagen promedio a partir de las intensidades medias de sus píxeles y un mapa de desvío

estándar que nos permitió visualizar la variabilidad interna de la categoría.

Como se observa en la Figura 5, la imagen promedio presenta una forma difusa, lo que sugiere diferencias entre las representaciones de los peces. Por otra parte, notamos que la mayor variabilidad se concentra en la región superior y los laterales de las imágenes, mientras que la región inferior presenta valores considerablemente menores.

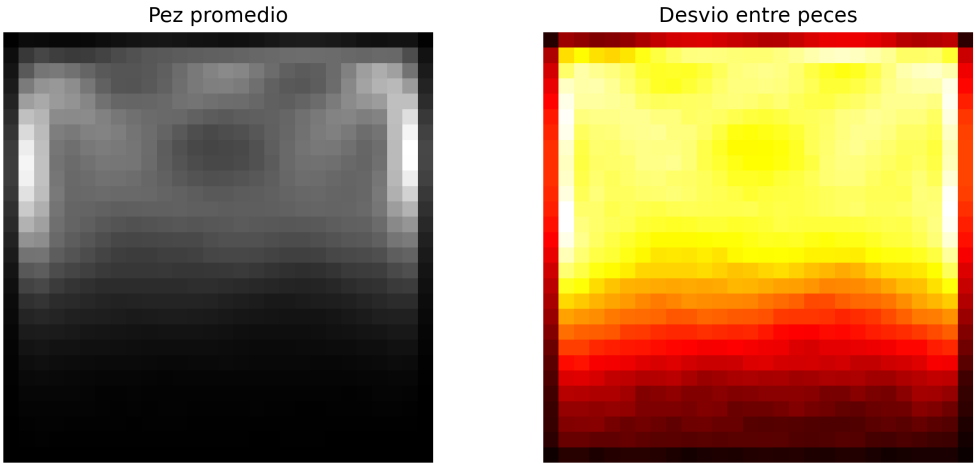


Figura 5: Imagen promedio y desvío estándar por píxel de la clase 3 (peces).

Para complementar estas observaciones, comparamos las distancias euclídeas entre pares de peces, entre peces y cuadrados y entre pares de cuadrados.

En la Figura 6 observamos que las distancias internas entre peces presentan una mediana cercana a 2900, ligeramente inferior a la distancia mediana entre peces y cuadrados, próxima a 3120. Sin embargo, las distribuciones se solapan considerablemente y las distancias internas de peces y cuadrados son similares.

Por lo tanto, encontramos variaciones apreciables entre las representaciones de peces, aunque su dispersión interna no resulta particularmente elevada en comparación con la de los cuadrados, según la distancia empleada. Estas observaciones no permiten determinar por sí solas qué tan fácilmente pueden clasificarse las imágenes de esta categoría.

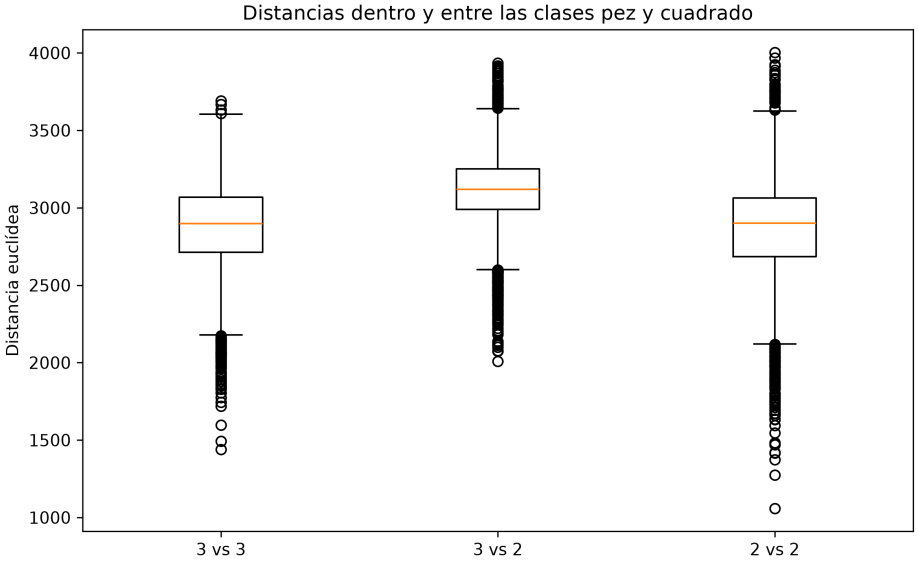


Figura 6: Distribución de las distancias euclídeas dentro de las clases 3 y 2, y entre ambas clases.

El análisis exploratorio de imágenes presenta dificultades asociadas a su alta dimensionalidad y

a la importancia de la disposición espacial de los píxeles. El estudio individual de las intensidades no permite recuperar completamente las formas de los dibujos, mientras que diferencias en la posición, el tamaño o la orientación pueden generar variaciones importantes dentro de una misma clase.

Para abordar estas dificultades, combinamos herramientas estadísticas y visuales que nos permitieron identificar patrones de variabilidad y similitud. Sin embargo, estos resultados no permiten determinar por sí solos la capacidad predictiva de los atributos ni la separabilidad de las clases. Por ello, en los siguientes ejercicios evaluamos empíricamente el desempeño de distintos clasificadores y cómo este cambia según los atributos e hiperparámetros seleccionados.

2. Experimentos realizados

En esta sección se describen los experimentos realizados, las decisiones tomadas durante el desarrollo y los resultados obtenidos. Para cada experimento se especifican el objetivo, la metodología y las observaciones principales.

2.1. Preparación de los datos

Antes de entrenar los modelos, se realizó [describir el preprocesamiento aplicado]. Se utilizaron los conjuntos de datos de entrenamiento y evaluación según lo establecido en la consigna.

Las decisiones de preparación de los datos se tomaron considerando [justificar brevemente las decisiones relevantes].

2.2. Primer experimento: [nombre del experimento]

El objetivo de este experimento fue [objetivo].

Para realizarlo, se utilizó [modelo o método], con [describir brevemente la configuración y los parámetros más importantes].

Los resultados obtenidos fueron [incluir resultados relevantes y métricas]. A partir de ellos, se observó que [interpretar el resultado, sin limitarse a repetir los valores].

2.3. Segundo experimento: [nombre del experimento]

En este experimento se buscó [objetivo], modificando [parámetros, atributos o modelo respecto del experimento anterior].

Se obtuvo [resultados principales]. La comparación con el experimento anterior permite observar que [interpretación de las diferencias].

2.4. Comparación de resultados

Para comparar los modelos y configuraciones evaluados, se resumen los resultados principales en la Tabla 1.

Cuadro 1: Comparación de los experimentos realizados.

Experimento	Métrica utilizada	Resultado
Experimento 1	[métrica]	[valor]
Experimento 2	[métrica]	[valor]
Experimento 3	[métrica]	[valor]

Los resultados muestran que [resumir qué configuración obtuvo el mejor desempeño y qué diferencias relevantes se encontraron].

3. Conclusiones

A partir de los experimentos realizados, se concluye que [resumir los principales hallazgos del trabajo].

En particular, el modelo [nombre del modelo] obtuvo [resultado relevante], mientras que [otro modelo o configuración] presentó [resultado]. Estas diferencias pueden explicarse por [justificación basada en los experimentos y las características de los datos].

Respecto del inciso 3.e, la accuracy estimada fue de [valor o porcentaje]. Esta estimación se obtuvo mediante [método utilizado para estimarla], utilizando [describir los datos o particiones empleados].

La estimación resulta razonable porque [justificar a partir del procedimiento de evaluación, los resultados obtenidos y las limitaciones que correspondan]. Sin embargo, debe tenerse en cuenta que [mencionar posibles limitaciones, incertidumbre o diferencias entre los datos utilizados para evaluar y los datos finales].

En síntesis, los resultados permiten afirmar que [conclusión final directamente respaldada por los experimentos realizados].

4. Bibliografía

Referencias

[1] [Autores del paper]. *[Título completo del paper].* [Revista, congreso o publicación, año]. [DOI o URL, si corresponde].